

UNIVERSIDAD GALILEO

FACULTAD DE INGENIERÍA DE SISTEMAS, INFORMÁTICA Y CIENCIAS



Predicción de Suscripción a Depósitos Bancarios mediante Aprendizaje Automático Supervisado

Análisis de campañas de marketing bancario

Postgrado de Inteligencia Artificial
Manejo de Datos para la IA — Segundo Trimestre

Autor

Diego Fernando Alvarez Muñoz

Guatemala, junio de 2026

Abstract

Las instituciones financieras destinan recursos considerables a campañas de marketing directo para promover depósitos a plazo, por lo que anticipar qué clientes aceptarán la oferta representa un valor operativo relevante. Este trabajo aborda dicho problema como una tarea de clasificación binaria supervisada utilizando el conjunto de datos bank-additional-full.csv del repositorio UCI, compuesto por 41,188 registros y 21 variables, correspondiente a campañas de un banco portugués. El conjunto presenta un marcado desbalance de clases, con 11.27 % de respuestas positivas. Se realizó un análisis exploratorio apoyado en pruebas de significancia, incluyendo chi-cuadrado, Mann-Whitney y Kolmogórov-Smirnov, así como un diagnóstico de calidad de datos que identificó valores unknown, registros duplicados, el valor especial pdays = 999, multicolinealidad severa entre indicadores económicos y fuga de información asociada a la variable duration. Posteriormente, se compararon cinco enfoques de modelado: Regresión Logística, SVM lineal, Random Forest, XGBoost y un ensamble por stacking, evaluados en dos escenarios: con y sin duration. En el escenario realista, sin duration, Random Forest y XGBoost obtuvieron el mejor desempeño, con PR-AUC ≈ 0.49 , ROC-AUC ≈ 0.81 y KS ≈ 0.53 , superando a los modelos lineales. Además, el modelo permitió capturar el 84 % de los suscriptores al contactar únicamente al 50 % de los clientes con mayor probabilidad estimada, lo que evidencia su utilidad para priorizar campañas comerciales bajo un enfoque predictivo.

Palabras clave: Bank Marketing; clasificación binaria; aprendizaje automático supervisado; desbalance de clases; XGBoost; interpretabilidad; fuga de información.

1. Introducción

El marketing directo busca identificar y contactar a los clientes con mayor probabilidad de adquirir un producto, con el propósito de optimizar el retorno de las campañas comerciales. En el sector bancario, los depósitos a plazo constituyen un instrumento relevante para captar pasivo estable, mientras que las campañas de telemarketing representan un canal habitual para su colocación. Sin embargo, contactar indiscriminadamente a toda la cartera puede resultar costoso e intrusivo; por ello, priorizar a los clientes con mayor propensión a suscribir un depósito representa una ventaja operativa concreta.

Este proyecto se enmarca en el caso Bank Marketing, ampliamente estudiado en la literatura de inteligencia artificial aplicada, aprendizaje automático y analítica predictiva. El trabajo de referencia de Moro, Cortez y Rita (2014) demostró que es posible predecir el éxito de una llamada de telemarketing utilizando información disponible antes del contacto, y que los indicadores socioeconómicos, en particular la tasa Euribor, se encuentran entre los predictores más relevantes. A partir de este antecedente, la pregunta de investigación que guía el estudio es:

¿Es posible predecir, antes de contactar al cliente, si aceptará un depósito a plazo, utilizando características del cliente, historial de campañas y variables del contexto económico, y cuál sería su utilidad para la toma de decisiones comerciales?

El objetivo de este trabajo es construir y comparar distintos modelos de clasificación, evaluarlos mediante métricas adecuadas para un problema desbalanceado y extraer conocimiento interpretable que respalde la toma de decisiones. Una premisa metodológica central atraviesa todo el estudio: la variable duration, correspondiente a la duración de la llamada, solo se conoce

una vez realizado el contacto y, por tanto, no está disponible al momento de decidir a qué clientes contactar. Por esta razón, los modelos se evalúan en dos escenarios: uno con duration, utilizado únicamente como referencia comparativa o benchmark, y otro sin dicha variable, definido como el escenario realista de despliegue.

2. Metodología

La metodología seguida permite reproducir el análisis desde la carga inicial de los datos hasta la interpretación del modelo con mejor desempeño. Para evitar inconsistencias durante la evaluación, el preprocesamiento y el entrenamiento se integraron dentro de un mismo Pipeline. De esta forma, las transformaciones que dependen de los datos, como la imputación, la codificación de variables categóricas o la estandarización, se ajustaron únicamente con la partición de entrenamiento en cada ciclo de validación cruzada. Este procedimiento evita que información del conjunto de prueba influya en el aprendizaje del modelo y asegura una estimación más confiable de su desempeño.

2.1 Conjunto de datos

El estudio se desarrolló con el archivo bank-additional-full.csv, la versión más completa del conjunto de datos Bank Marketing, compuesto por 41,188 registros y 21 variables. Estas variables se agrupan en características del cliente, información del contacto y de campañas previas, e indicadores socioeconómicos. La variable objetivo, **y**, señala si el cliente aceptó o no la suscripción del depósito a plazo. Esta versión fue seleccionada sobre bank-full.csv porque, aunque esta última contiene más registros, no incluye indicadores socioeconómicos como el Euribor a tres meses, la variación del empleo o los índices de precios y confianza del consumidor, variables que la literatura previa ha señalado como relevantes para predecir la respuesta del cliente en este tipo de campañas.




Figura 1. Distribución de la variable objetivo. El conjunto está fuertemente desbalanceado: 88.73% no y 11.27% sí.

El desbalance de clases observado en la Figura 1 limita la utilidad de la exactitud (accuracy) como métrica principal de evaluación. En este caso, un clasificador que asignara todos los registros a la clase mayoritaria alcanzaría una exactitud cercana al 89%, sin aportar capacidad real para identificar a los clientes que sí suscriben el depósito. Por esta razón, la evaluación se centró en métricas más adecuadas para problemas desbalanceados.

2.2 Diagnóstico de calidad de datos

El diagnóstico de calidad de datos permitió identificar varios aspectos relevantes para el preprocesamiento. Aunque el conjunto no presenta valores nulos formales, algunas variables categóricas utilizan la categoría unknown para representar información no disponible. Esta situación se observa principalmente en default, con 20.87% de registros, seguida de education con 4.20%, housing y loan con 2.40%, job con 0.80% y marital con 0.19%. Estos valores se conservaron como una categoría explícita, dado que pueden reflejar patrones propios del proceso de captura o segmentación de clientes.

La variable default requirió un tratamiento particular. Además de concentrar el mayor porcentaje de valores unknown, presenta una distribución casi constante: únicamente 3 de los 41,188 registros tienen el valor yes. Debido a su baja variabilidad y escaso aporte discriminante, esta variable fue excluida del modelado. Asimismo, se identificaron 12 registros completamente duplicados, los cuales fueron eliminados para evitar redundancias en el entrenamiento.

Otro caso relevante fue la variable pdays, donde el valor 999 aparece en el 96.32 % de los registros. Este valor no representa una cantidad real de días, sino que indica que el cliente no había sido contactado previamente. Por esta razón, se reemplazó por una variable binaria, contacted_prev, que distingue entre clientes con y sin contacto anterior.

Finalmente, se analizó la variable duration, correspondiente a la duración de la llamada. Esta variable mostró una relación muy marcada con la respuesta del cliente: las llamadas exitosas tuvieron una duración promedio de 553 segundos, frente a 221 segundos en las no exitosas; además, todas las llamadas con duración igual a cero terminaron en una respuesta negativa. Sin embargo, dado que esta información solo se conoce después de realizar el contacto, su uso en un modelo destinado a priorizar clientes antes de llamarlos constituiría fuga de información. Por ello, duration se excluyó del escenario realista de despliegue y se mantuvo únicamente en un escenario de referencia comparativa.




Figura 2. Cantidad y porcentaje de valores “unknown” por variable.

Las distribuciones y los posibles valores extremos de las variables numéricas se evaluaron mediante histogramas y diagramas de caja, tomando como referencia la regla del rango intercuartílico (IQR), como se ilustra en la Figura 3. Los valores atípicos observados en previous, campaign y duration corresponden a colas largas propias del dominio, dado que la mayoría de los clientes registra pocos contactos y llamadas breves, mientras que una minoría presenta valores considerablemente más altos. En pdays, los valores extremos responden principalmente

a la codificación especial 999, utilizada para indicar ausencia de contacto previo. Las variables económicas, en cambio, no presentaron valores atípicos relevantes. Por esta razón, no se eliminaron observaciones y se priorizó el uso de modelos adecuados para distribuciones asimétricas y con colas largas.




Figura 3. Diagramas de caja de las variables numéricas; los puntos fuera de los bigotes son valores extremos según la regla IQR.

2.3 Análisis inferencial y multicolinealidad

Para diferenciar asociaciones estadísticamente respaldadas de posibles variaciones muestrales, se aplicaron pruebas de significancia según el tipo de variable. En el caso de las variables categóricas, se utilizó la prueba de chi-cuadrado junto con la V de Cramér para evaluar su relación con la variable objetivo. Para las variables numéricas, se emplearon las pruebas de Mann-Whitney y Kolmogórov-Smirnov de dos muestras. Los resultados mostraron asociaciones relevantes entre la suscripción del depósito y variables como poutcome, contact, month y los indicadores económicos.

Adicionalmente, se evaluó la colinealidad entre los indicadores económicos, como se muestra en la Figura 4. La tasa Euribor a tres meses presentó una correlación de 0.97 con la tasa de variación del empleo y de 0.95 con el número de empleados. Este nivel de correlación evidencia una multicolinealidad importante entre variables macroeconómicas. En consecuencia, la interpretación individual de los coeficientes en la Regresión Logística debe realizarse con cautela, ya que el efecto asociado a cada variable puede no separarse claramente. De forma similar, en los modelos basados en árboles, la importancia puede distribuirse entre predictores que contienen información redundante. Por ello, la multicolinealidad se considera una limitación interpretativa explícita del análisis.




Figura 4. Matriz de correlación entre las variables económicas. Se observan correlaciones superiores a 0.9.




Figura 5. Tasa de suscripción por resultado de campaña previa (izq.) y por mes de contacto (der.).

El análisis exploratorio mostró patrones consistentes con la lógica del negocio. Los clientes con resultado exitoso en una campaña anterior presentaron una tasa de suscripción superior al 65%. Asimismo, el contacto por canal celular mostró una tasa de aceptación cercana al triple de la observada en teléfono fijo. También se identificaron diferencias relevantes según el mes de contacto: marzo, septiembre, octubre y diciembre registraron tasas de suscripción notablemente superiores a mayo.

2.4 Preprocesamiento sin fuga de información

El preprocesamiento se integró dentro de un ColumnTransformer y se ejecutó como parte de un Pipeline, con el propósito de mantener un flujo consistente entre entrenamiento y evaluación. En esta etapa se eliminaron los registros duplicados y la variable default, debido a su baja variabilidad. También se transformó pdays en la variable binaria contacted_prev, ya que el valor 999 no representa una cantidad real de días, sino la ausencia de contacto previo. Las categorías unknown se conservaron como valores explícitos, dado que pueden contener información relevante sobre la disponibilidad de datos o el perfil del cliente. Las variables categóricas fueron codificadas mediante One-Hot Encoding, mientras que las variables numéricas se escalonaron únicamente en los modelos sensibles a la escala, como Regresión Logística y SVM lineal. Finalmente, se trabajó con dos versiones del conjunto de variables: una con duration, utilizada como escenario de referencia o benchmark, y otra sin duration, considerada el escenario realista de despliegue.

2.5 Estrategia de validación

Para la evaluación se utilizó una partición estratificada 75/25, complementada con validación cruzada estratificada de cinco pliegues durante el ajuste y comparación de los modelos. Esta estrategia permitió conservar la proporción original de clases tanto en entrenamiento como en prueba. Sin embargo, dado que los registros mantienen un orden cronológico y que los indicadores económicos tienden a permanecer relativamente estables dentro de ciertos periodos, también se incorporó un holdout ordenado por posición. En este esquema, las primeras observaciones se utilizaron para entrenar y las últimas para probar, aproximando una evaluación temporal más cercana a un escenario de uso real. Este ejercicio permitió analizar qué tan sensible es el desempeño del modelo ante cambios en el tiempo. El desbalance de clases se abordó mediante ponderación de clases, utilizando `class_weight` y `scale_pos_weight`, junto con un ajuste posterior del umbral de decisión, evitando así recurrir a técnicas de remuestreo que pudieran alterar de forma agresiva la distribución original de los datos.

2.6 Modelos y métricas

Se compararon cinco enfoques de modelado con distintos niveles de complejidad: Regresión Logística, SVM lineal calibrado, Random Forest, XGBoost y un ensamble por stacking con meta-modelo logístico. Los modelos Random Forest y XGBoost fueron ajustados mediante búsqueda aleatoria de hiperparámetros, utilizando PR-AUC como métrica de optimización dentro de la validación cruzada. Esta métrica se tomó como principal debido al desbalance de clases, ya que permite evaluar mejor la capacidad del modelo para identificar correctamente los casos positivos. Además, se reportaron ROC-AUC, el estadístico Kolmogórov-Smirnov —habitual en problemas de scoring bancario—, precisión, recall, F1 y exactitud como medida de referencia. La evaluación se complementó con la matriz de confusión, la curva de ganancias acumuladas o Lift y el análisis de calibración de probabilidades, con el fin de valorar no solo el desempeño predictivo, sino también la utilidad práctica del modelo para priorizar clientes.

3. Resultados

3.1 Comparación de modelos

La Tabla 1 presenta el desempeño de los modelos en el conjunto de prueba para el escenario realista, es decir, sin considerar la variable duration. En este escenario, Random Forest y el ensamble por stacking obtuvieron los mejores resultados, mientras que XGBoost mostró un desempeño muy cercano. Los modelos lineales, aunque competitivos, quedaron ligeramente por debajo de los enfoques basados en árboles y ensambles. El ROC-AUC cercano a 0.81 se mantiene en línea con el valor de 0.79 reportado por Moro, Cortez y Rita (2014) bajo una evaluación sin información posterior al contacto.

Tabla 1. Desempeño en el escenario realista (sin duration).

Modelo	PR-AUC	ROC-AUC	KS	F1	Recall
Random Forest	0.494	0.813	0.528	0.504	0.635
Stacking	0.490	0.814	0.526	0.375	0.262
XGBoost	0.479	0.809	0.523	0.478	0.651
Regresión Logística	0.443	0.801	0.503	0.464	0.639
SVM lineal	0.439	0.802	0.503	0.313	0.207

El escenario benchmark, que incluye la variable duration, muestra una mejora considerable en el desempeño predictivo. En particular, el ROC-AUC del modelo stacking aumenta de 0.81 a 0.95, mientras que el PR-AUC pasa de 0.49 a 0.67, como se observa en la Tabla 2. Esta diferencia evidencia el aporte predictivo de una variable que no estaría disponible antes de realizar la llamada. Por ello, aunque duration mejora notablemente los resultados, su inclusión no es adecuada para un modelo operativo orientado a decidir qué clientes contactar.

Tabla 2. Desempeño en el escenario benchmark (con duration).

Modelo	PR-AUC	ROC-AUC	KS	Brier
Stacking	0.668	0.950	0.798	0.056
XGBoost	0.652	0.949	0.795	0.085
Random Forest	0.648	0.945	0.790	0.058
Regresión Logística	0.584	0.939	0.778	0.101
SVM lineal	0.585	0.939	0.773	0.064

3.2 Significancia estadística

Para verificar que las diferencias de desempeño no dependieran únicamente de una partición específica de los datos, se estimó el PR-AUC por pliegue mediante validación cruzada repetida 5×3. Posteriormente, se aplicó una prueba pareada de Mann-Whitney para comparar el desempeño entre modelos. Los resultados muestran que Random Forest obtuvo un PR-AUC promedio de 0.4658 ± 0.0129 y XGBoost de 0.4626 ± 0.0143 , sin diferencias estadísticamente significativas entre ambos modelos ($p = 0.2669$). En cambio, ambos superaron de manera significativa a la Regresión Logística ($p = 0.0005$) y al SVM lineal ($p < 0.001$). Esto sugiere que la mejora de los modelos no lineales frente a los lineales es consistente, mientras que la elección entre Random Forest y XGBoost puede apoyarse en criterios adicionales, como interpretabilidad, estabilidad o costo computacional.

3.3 Sensibilidad temporal

En el holdout ordenado por posición, el desempeño de XGBoost disminuyó de forma considerable respecto a la partición estratificada. El modelo pasó de un PR-AUC de 0.479 en la partición aleatoria estratificada a un PR-AUC de 0.358 en el esquema ordenado, con un ROC-AUC de 0.588 y un KS de 0.143. Esta diferencia sugiere que parte del desempeño observado bajo muestreo aleatorio puede estar asociado a información temporal capturada por los

indicadores económicos, los cuales funcionan como una aproximación del periodo en que se realizó la campaña. Por ello, este resultado se reconoce como una limitación relevante del estudio y señala que un despliegue real debería considerar reentrenamiento periódico y esquemas de validación temporal, como ventanas móviles.

3.4 Valor de negocio

La curva de ganancias acumuladas, presentada en la Figura 6, permite interpretar el desempeño del modelo en términos operativos. Al ordenar a los clientes según su probabilidad estimada de suscripción, el 20% con mayor puntuación concentra el 65.8% de los suscriptores, mientras que el 50% mejor clasificado concentra el 83.7%. En la práctica, esto implica que el modelo permitiría reducir aproximadamente a la mitad el esfuerzo de contacto, manteniendo más del 80 % de las conversiones potenciales. Este resultado es consistente con el 79% reportado por Moro, Cortez y Rita (2014), lo que refuerza la utilidad del enfoque predictivo para priorizar campañas de telemarketing bancario.




Figura 6. Curva de ganancias acumuladas (Lift). La línea roja marca el 50% de la cartera.

3.5 Modelo seleccionado y umbral de decisión

Se seleccionó Random Forest como modelo final para el escenario realista, principalmente por su desempeño en PR-AUC y por mostrar una calibración adecuada de las probabilidades estimadas. Su comportamiento se resume mediante la matriz de confusión de la Figura 7 y la curva de calibración de la Figura 8. Debido al desbalance de clases, utilizar un umbral estándar de 0.5 no necesariamente ofrece el mejor equilibrio entre precisión y recall. Por ello, el umbral de decisión se ajustó a partir de la validación cruzada, maximizando el F1. Con este procedimiento se obtuvo un umbral de 0.681, que en el conjunto de prueba alcanzó una precisión de 0.492, un recall de 0.551 y un F1 de 0.52. Este umbral no debe interpretarse como fijo, sino como un punto de operación ajustable según la capacidad de contacto disponible y los objetivos comerciales de la campaña, como se ilustra en la Figura 9.

Matriz de confusión — Random Forest




Figura 7. Matriz de confusión del modelo Random Forest (umbral 0.5).




Figura 8. Curva de calibración del modelo Random Forest.




Figura 9. Precisión, recall y F1 en función del umbral de decisión.

3.6 Interpretabilidad

Para analizar la lógica predictiva del modelo, se aplicó SHAP sobre XGBoost, como se muestra en la Figura 10. Este enfoque permite estimar la contribución de cada variable a las predicciones del modelo y cumple una función similar al análisis de sensibilidad utilizado por Moro, Cortez y Rita (2014). Las variables con mayor influencia fueron el número de empleados, la tasa de variación del empleo y el canal de contacto celular, seguidas por el Euribor a tres meses, el índice de confianza del consumidor, el número de contactos durante la campaña y el indicador de contacto previo. Estos resultados son consistentes con la literatura previa, en la medida en que resaltan el peso de las variables económicas y temporales en la probabilidad de suscripción. En particular, valores bajos del número de empleados y del Euribor se asociaron con una mayor probabilidad estimada de que el cliente aceptara el depósito.




Figura 10. Importancia y efecto de las variables según SHAP (modelo XGBoost).

4. Conclusiones

Los resultados muestran que es posible predecir con utilidad práctica la suscripción a depósitos a plazo utilizando únicamente información disponible antes del contacto con el cliente. En el escenario realista, es decir, sin considerar la variable *duration*, Random Forest y XGBoost alcanzaron los mejores desempeños, con un PR-AUC cercano a 0.49 y un ROC-AUC cercano a 0.81. Ambos modelos superaron a los enfoques lineales, mientras que el ensamble por stacking obtuvo un desempeño similar al mejor modelo, pero sin aportar una mejora suficiente que justificara su mayor complejidad.

Desde una perspectiva operativa, el modelo permite priorizar a los clientes con mayor probabilidad de suscripción y reducir el esfuerzo de contacto sin perder una proporción importante de conversiones potenciales. En particular, al contactar al 50 % de los clientes mejor clasificados, se captura más del 80 % de los suscriptores. Este resultado sugiere que el uso de modelos predictivos puede contribuir a campañas más eficientes, menos intrusivas y mejor orientadas comercialmente.

El análisis de interpretabilidad mostró que las variables relacionadas con el contexto económico y temporal, en particular el Euribor y la variación del empleo, junto con el canal de contacto, se encuentran entre los factores con mayor influencia en la probabilidad estimada de suscripción. Estos hallazgos son consistentes con la literatura de referencia y refuerzan la importancia de considerar no solo características individuales del cliente, sino también condiciones externas asociadas al momento de la campaña.

El estudio también presenta algunas limitaciones. En primer lugar, la variable *duration* mostró una alta capacidad predictiva, pero no puede utilizarse en producción porque solo se conoce después de realizada la llamada. En segundo lugar, la caída de desempeño observada en el holdout ordenado indica que el modelo es sensible a las condiciones económicas del periodo de entrenamiento, por lo que su desempeño podría variar ante cambios temporales. En tercer lugar, la alta correlación entre los indicadores económicos dificulta la interpretación individual de sus efectos, especialmente en modelos lineales. Finalmente, la variable *default* fue descartada debido a su baja variabilidad y escaso aporte discriminante.

Como trabajo futuro, se propone incorporar esquemas de validación temporal mediante ventanas móviles, evaluar estrategias de remuestreo dentro del Pipeline y explorar modelos adicionales, como redes neuronales, siempre contrastando su desempeño con la interpretabilidad, estabilidad y utilidad operativa requeridas en un contexto bancario.

Referencias

- Moro, S., Cortez, P., & Rita, P. (2014). A data-driven approach to predict the success of bank telemarketing. *Decision Support Systems*, 62, 22–31.
- Moro, S., Laureano, R., & Cortez, P. (2012). Enhancing bank direct marketing through data mining. En *Proceedings of the 41st EMAC Conference*. European Marketing Academy.
- Tanvir, M. F., Hossain, M. M., & Jishan, M. A. (2024). Bayesian Regression for Predicting Subscription to Bank Term Deposits in Direct Marketing Campaigns. *arXiv:2410.21539*.
- Moro, S., Rita, P., & Cortez, P. (2012). Bank Marketing [Conjunto de datos]. UCI Machine Learning Repository.
- Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. En *Advances in Neural Information Processing Systems (NeurIPS)*, 30.